


YOLOX推論プロセスの全貌

画像入力から物体検出までのステップ・バイ・ステップ解剖



アンカーベースの伝統を打ち破り、物体検出の新たな頂点へ

圧倒的なパフォーマンス

50.0% AP
68.9 FPS

※YOLOX-Lモデル
(Tesla V100での測定値)

革新1：Anchor-Free
(アンカーフリー)




ヒューリスティックな調整を完全に排除し、パラメータ数を削減。エッジデバイスにおける推論を劇的に高速化。

革新2：Decoupled Head
(分離型ヘッド)



分類と回帰という根本的に異なるタスクの衝突を解消し、モデルの収束速度と最終精度を最大化。

入力から出力までの5つのステップ：YOLOX推論パイプライン



パイプライン・カラーコード

- 入力データ・バックボーン構造
- クラス分類タスク（何であるか）
- 回帰・座標タスク（どこにあるか）
- オブジェクト性（物体が存在するか）

ステップ1：モデルが解釈できるテンソル形式への画像変換

前処理パイプライン



1. リサイズ

画像を 640 × 640 ピクセルに調整




2. 正規化

各ピクセルのRGB値を
計算用のスケールに変換



3. テンソル化


HWC形式からBCHW形式の
多次元配列へ再構成



推論入力用テンソル: $[1 \times 3 \times 640 \times 640]$

ステップ2：DarkNet53/CSPNetによる空間的・意味的特徴の抽出

バックボーン・ネットワーク (空間解像度の縮小と抽象化)



P3 レベル特徴マップ

80 × 80 グリッド

高解像度：微細なエッジや小物体に強い空間情報

P4 レベル特徴マップ

40 × 40 グリッド


中解像度：バランスの取れた特徴

P5 レベル特徴マップ

20 × 20 グリッド

低解像度：全体的な文脈を捉える強い意味情報

ステップ3：FPN/PANによるマルチスケール特徴の統合




ステップ4：YOLOX最大の革新「分離型ヘッド」への到達

従来の Coupled Head (タスクの衝突)




分類と回帰を同一のネットワークで処理するため、空間的な不整合 (Spatial misalignment) が生じ、精度向上のボトルネックとなる。

YOLOXの Decoupled Head (独立した最適化)




タスクごとの専用経路を設けることで衝突を完全に解消。収束速度が劇的に向上し、エンドツーエンド推論の精度低下も防ぐ。

ステップ5：3つの独立したブランチが担う「クラス」「座標」「オブジェクト性」



ステップ5：アンカーフリー設計がもたらす予測パラダイムの転換


従来のアンカーベース手法



手動で設計されたアンカーボックス

- 各グリッドにつき複数の事前定義ボックスが必要
- ヒューリスティックな調整が不可欠
- パラメータ数が膨大になり、転送遅延の原因に


YOLOX アンカーフリー手法



ダイナミックな中心点予測

- 各グリッドにつき予測は1つのみ
- 事前定義されたアンカー枠を完全に排除
- 後処理を大幅に簡素化し、推論スピードを加速

グリッド座標からのダイナミックなバウンディングボックス生成




アンカーを介さない直接座標計算

最終的な物体の中心座標
= グリッド位置 (c) + 予測オフセット (d)

複雑なIoU計算を用いたアンカーマッチングを排除し、ネットワークの出力を直接ピクセル空間の寸法へと変換する極めてシンプルなデコーディング手法。


最終ステップ：信頼度フィルタリングとNMSによる重複排除

1. ネットワークからの全予測




複数スケールにわたる数千個の生予測ボックスが出力された状態。

2. スコア閾値によるフィルタリング




オブジェクト性スコア×クラス確率が低い（閾値以下の）ノイズボックスを除外。

3. NMS (Non-Maximum Suppression)



IoU（重なり度合い）を計算し、同一物体を指している重複ボックスのうち、最も精度の高い1つだけを最終出力として採用。

画像入力からJSON出力までを一気通貫で理解する



エッジからクラウドまで網羅するスケーラビリティ

SimOTAや強力なデータ拡張（MixUp等）により、すべてのスケールで最先端の精度を達成。

モデル	パラメータ数 (M)	レイテンシ (V100 ms)	COCO AP (%)
YOLOX-Nano	0.91	-	25.3
YOLOX-Tiny	5.06	-	32.8
YOLOX-S	9.0	9.8	39.6
YOLOX-M	25.3	12.3	46.4
YOLOX-L	54.2	14.5	50.0
YOLOX-X	99.1	17.3	51.2

モバイル・エッジデバイス
向け極小モデル

クラウドサーバー向け
高精度モデル /
YOLOv5-Lを凌駕

高速化と高精度を両立させたYOLOXの実践的価値




推論プロセスの 中間搾取を排除

アンカーフリーパラダイムの採用により、ヒューリスティックな計算と膨大な後処理パラメータを劇的に削減。データの転送遅延を防ぎ、実運用環境での真の高速化を実現。



ネットワークアーキ テクチャの最適化

最大の革新である「分離型ヘッド (Decoupled Head)」により、分類タスクと回帰タスクの根本的な衝突を解消。推論スピードを犠牲にすることなく、驚異的な検出精度を叩き出す。



あらゆる環境への デプロイメント

モバイル向け0.91MのNanoから、クラウドGPU向けの大規模模Xモデルまで一貫したアーキテクチャを維持。ONNX、TensorRT、OpenVINO等を用いた即座の展開が可能。

オープンソース・リファレンス実装

<https://github.com/Megvii-BaseDetection/YOLOX>